

Laporan Praktikum Minggu Ke-5 Kontrol Cerdas

Minggu ke-5

Nama : Nisa Ayu Maslikhah

NIM : 224308064

Kelas : TKA 7C

Akun Github (Tautan): <https://github.com/nisaayumaslikhah>

1. Judul Percobaan

Deep Reinforcement Learning untuk Kontrol Kompleks

2. Tujuan Percobaan

Tujuan dari percobaan ini, sebagai berikut:

- a. Memahami konsep Deep Reinforcement Learning (DRL) dalam kontrol sistem kompleks.
- b. Mengimplementasikan Deep Q-Network (DQN) untuk kontrol otomatis.
- c. Menganalisis performa DRL dibandingkan dengan metode kontrol konvensional.

3. Landasan Teori

DRL (Deep Reinforcement Learning) adalah metode pembelajaran mesin yang menggabungkan prinsip pembelajaran berpenguatan dengan arsitektur jaringan saraf tiruan yang dalam. DRL telah digunakan secara luas dalam pengembangan kendaraan otonom untuk menghasilkan kebijakan kontrol adaptif yang optimal melalui interaksi dengan lingkungan (Pratama, 2024). Metode DRL menggantikan representasi Q-Value yang bersifat tabel (Q-Table) pada RL klasik dengan Neural Network, sehingga mampu menangani skala masalah yang lebih besar dan state yang lebih kompleks secara efektif. Algoritma DRL populer antara lain Deep Q-

Network (DQN), Proximal Policy Optimization (PPO), dan Asynchronous Advantage Actor-Critic (A3C).

DQN adalah algoritma DRL yang paling umum digunakan untuk kontrol adaptif. DQN menggantikan tabel Q-value dengan Neural Network yang memprediksi nilai Q untuk setiap aksi pada state yang diberikan. Arsitektur DQN terdiri dari beberapa lapisan Neural Network yang menerima input berupa state lingkungan (sensor, kondisi sistem, dll), dan menghasilkan output berupa nilai Q untuk setiap aksi yang mungkin diambil. Proses pelatihan DQN menggunakan fungsi loss berupa Mean Squared Error antara prediksi dan target Q-Value, serta memanfaatkan replay memory untuk menyimpan pengalaman agar pelatihan menjadi lebih stabil. Penggunaan strategi epsilon-greedy memungkinkan keseimbangan antara eksplorasi dan eksploitasi dalam pengambilan Keputusan (Ridho Amanda Putra, 2024).

Analisis performa Deep Reinforcement Learning (DRL) dibandingkan dengan metode kontrol konvensional seperti PID dan Fuzzy Logic menunjukkan sejumlah perbedaan dan keunggulan pada masing-masing metode. DRL, dengan algoritma seperti Deep Q-Network (DQN), mampu belajar mengoptimalkan kebijakan kontrol melalui interaksi langsung dengan lingkungan dan menerima feedback berupa reward, sehingga metode ini sangat adaptif terhadap kondisi sistem yang kompleks dan dinamis tanpa memerlukan model matematis yang rinci. Dibandingkan dengan DRL, metode pembelajaran ini menawarkan fleksibilitas dan kemampuan adaptasi yang lebih baik pada sistem kompleks dan kondisi lingkungan berubah-ubah. DRL bisa belajar dari pengalaman dan menyesuaikan strategi kontrol sehingga performa keseluruhan sistem menjadi lebih optimal dan robust dibandingkan kontrol konvensional.

Namun, DRL memerlukan komputasi lebih besar dan waktu pelatihan yang lebih lama dibanding PID dan FLC. Meskipun DQN unggul dalam pengolahan state kompleks, penggunaan algoritma ini memerlukan pengaturan parameter yang cermat seperti strategi eksplorasi epsilon-greedy agar proses pelatihan berjalan efektif (Gunawan & Santosa, 2023). Sejarah dan teori dasar reinforcement learning

yang mendasari DRL tersebut menunjukkan bahwa algoritma ini sangat potensial untuk diterapkan pada sistem kontrol otomasi dan kendaraan otonom yang memerlukan adaptasi cepat terhadap perubahan lingkungan.

4. Diskusi

a. Apa kelebihan dan kelemahan DQN dibandingkan metode Q-Learning klasik?

- Kelebihan

Deep Q-Network (DQN) memiliki kelebihan utama dibandingkan dengan metode Q-Learning klasik karena menggunakan jaringan saraf untuk memprediksi nilai Q, sehingga DQN dapat menyelesaikan masalah dengan ruang yang besar dan kompleks serta bersifat berkelanjutan. Namun, Q-Learning menggunakan tabel Q-Value (Q-Table) yang hanya dapat digunakan pada masalah dengan ruang state diskrit dan kecil. DQN mengatasi keterbatasan *Q-learning* tradisional, seperti masalah skalabilitas dan kurangnya kemampuan generalisasi. Selain itu, DQN dapat melakukan generalisasi, dengan mengaplikasikan pengetahuan dari satu state ke state lain yang serupa, sehingga dapat menjadikan lebih efisien dalam masalah kompleks dan dinamis.

- Kelemahan

DQN juga memiliki kelemahan, seperti halnya pada tingkat kesulitan komputasi yang jauh lebih tinggi dibandingkan Q-Learning karena melibatkan pelatihan jaringan saraf yang membutuhkan sumber daya dan waktu lebih banyak. DQN memerlukan pelatihan khusus, sehingga implementasinya lebih rumit dibandingkan Q-Learning klasik yang lebih sederhana dan simpel, serta mudah diaplikasikan dengan ruang state yang kecil.

b. Bagaimana cara mengadaptasi DQN untuk kontrol sistem dinamis seperti drone atau robot industri?

Untuk mengadaptasi Deep Q-Network (DQN) guna mengendalikan sistem dinamis seperti drone atau robot industri, data sensor seperti posisi dan

kecepatan harus terlebih dahulu digunakan sebagai masukan yang dinormalisasi agar jaringan saraf dapat memprosesnya dengan mudah. Selanjutnya, ruang aksi atau kemungkinan aksi harus disesuaikan dengan kemampuan sistem, seperti pergerakan motor atau aktuator. Jika aksi bersifat kontinu, biasanya perlu dimodifikasi atau menggunakan algoritma berbeda yang mendukung aksi kontinu. Untuk memastikan pelatihan DQN yang stabil dan hasil yang baik, teknik memori replay digunakan untuk menyimpan nilai pengalaman dan batch pelatihan acak, serta tujuan jaringan yang diperbarui secara berkala. Biasanya, model dilatih terlebih dahulu dalam simulasi untuk memastikan keamanannya, kemudian diuji dalam sistem nyata, dengan memperhatikan responsivitas dan keamanan sistem. Dengan metode ini, DQN dapat belajar mengendalikan sistem kompleks secara adaptif dan efektif.

5. Assignment


Pada praktikum kali ini, mengimplementasikan pada deteksi objek seperti pose manusia, dan deteksi tangan serta jari secara simultan. Dimana program membentuk sebuah aplikasi real-time yang menggunakan pustaka OpenCV dan MediaPipe untuk mendeteksi dan memvisualisasikan pose tubuh lengkap dan tangan manusia dari video kamera. MediaPipe digunakan untuk mendeteksi key points tangan dan pose tubuh, kemudian OpenCV menampilkan hasil berupa skeleton dengan garis dan titik sendi, serta bounding box di sekitar tangan dan tubuh yang terdeteksi. Pada bagian tangan, kode ini mampu mendeteksi hingga enam tangan sekaligus dan menampilkan label "Left" atau "Right" lengkap dengan confidence score. Sementara pada pose tubuh, titik-titik landmark digambar bersama bounding box dan label "Person".

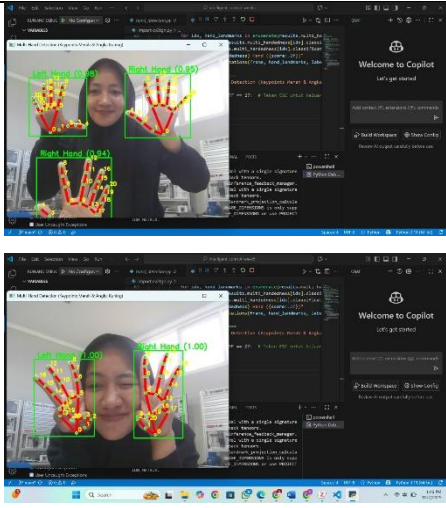

Selain visualisasi, kode juga menyimpan koordinat titik pose tubuh dalam file CSV berisi frame, indeks joint, koordinat x, y, z, dan tingkat visibilitas, yang berguna untuk analisis data lebih lanjut. Frame kamera diolah secara berkelanjutan, dibalik horizontal agar tampilan seperti cermin, dan

diproses deteksi melalui MediaPipe dalam satu loop yang sama. Kamera dipicu oleh cv2.VideoCapture(0) untuk menangkap gambar secara real-time. Setiap gambar yang diterima dikonversi ke format RGB agar sesuai dengan input yang dibutuhkan oleh MediaPipe. Deteksi tangan dilakukan menggunakan model Hands(), yang dapat mendeteksi hingga dua tangan dengan tingkat kepercayaan minimum 0,7 untuk deteksi dan pelacakan. Jika tangan terdeteksi dengan benar, sistem akan menggambar landmark dan koneksi antar landmark menggunakan fungsi mp_drawing.draw_landmarks(). Selain itu, setiap landmark diberi label angka (0–20) dan diapit dalam kotak hijau untuk menyorot area tangan yang terdeteksi. Secara keseluruhan, aplikasi ini sangat berguna dalam bidang interaksi manusia-komputer, analisis gerakan, atau studi terkait pengenalan gestur dan pose, karena mampu menampilkan dan merekam data secara lengkap dan akurat dari posisi tubuh dan tangan manusia secara real-time.

6. Data dan Output Hasil Pengamatan

Pada praktikum didapatkan hasil pengujian untuk mendeteksi dan melacak posisi tubuh serta tangan manusia secara real-time melalui kamera web sebagai berikut:

No	Variable	Hasil Pengamatan	Keterangan
1.	Deteksi Dua Tangan		Berdasarkan gambar menunjukkan hasil deteksi kedua tangan secara otomatis dengan kotak hijau dan label “Left Hand” serta “Right Hand” menggunakan program berbasis OpenCV dan MediaPipe secara real-time. Jika tangan melebihi dua maka tidak akan terdeteksi dan selanjutnya akan dilakukan modifikasi

			program agar dapat mendeteksi multi tangan.
2.	Deteksi Multi-Tangan		Semua tangan terdeteksi, atau dapat mendeteksi lebih dari dua tangan sekaligus, serta terdapat 20 titik per tangan dan dimana garis hijau menghubungkan sendi di setiap titik merah nya.
3.	Deteksi Badan		Program dapat mendeteksi sendi sendi pada seluruh tubuh secara real time. Selain itu, hanya manusia yang dapat terdeteksi, objek lain seperti noise yang ada diabaikan.

7. Kesimpulan

Berdasarkan praktikum, analisis, dan hasil yang telah dilakukan, dapat disimpulkan bahwa:

- Sistem ini memanfaatkan kekuatan MediaPipe untuk mengenali dan memetakan posisi titik-titik sendi tubuh dan tangan secara akurat, serta OpenCV untuk menyediakan visualisasi yang informatif dengan berbagai elemen grafik seperti skeleton, bounding box, label, dan indeks titik sendi.

- b. Tingkat akurasi model sangat bergantung pada kualitas data sheet serta parameter yang digunakan sehingga optimasi melalui perbaikan data sheet penyetelan model dan peningkatan performa Real Time dapat meningkatkan hasil deteksi.
- c. Sistem ini berpotensi besar untuk diterapkan pada berbagai aplikasi, seperti pemantauan aktivitas fisik, kontrol perangkat berbasis gerakan, hingga pengembangan sistem interaksi berbasis gestur.

8. Saran

Optimasi pada penerapan multi-threading juga perlu dilakukan guna mencegah terjadinya bottleneck saat ketiga proses deteksi (objek, pose, dan tangan) berjalan secara paralel. Percobaan sebaiknya didukung pencahayaan pada berbagai kondisi dan sudut kamera untuk meningkatkan ketahanan deteksi. Selain itu, perlu memberikan batasan jumlah tangan atau pose yang dideteksi sesuai kebutuhan untuk mengoptimalkan performa aplikasi agar tetap responsif pada perangkat dengan spesifikasi lebih rendah.

9. Daftar Pustaka

- Pratama, D. A. S. (2024). Pengembangan Kontrol Adaptif untuk Kendaraan Otonom dengan Studi Kasus pada Mobil Elektrik Berbasis Deep Reinforcement Learning.
- Ridho Amanda Putra. (2024). ANALISIS DEEP Q-NETWORK (DQN) UNTUK SIMULASI LAMPU LALU LINTAS ADAPTIF BERDASARKAN WAKTU TUNGGU KENDARAAN.